

CÁLCULO NUMÉRICO

Ajuste de Curvas

Gustavo Bono

Universidade Federal de Pernambuco
Centro Acadêmico do Agreste
Núcleo de Tecnologia
Caruaru - Brasil

2017.2

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono




1) Ajuste de Curvas: Introdução

- a) Existem **duas classes de métodos** para a aproximação de dados, e a distinção entre elas está em **considerarmos, ou não, a existência de erro nos dados**;
- b) No primeiro caso, os métodos levam em consideração possíveis erros introduzidos na obtenção dos dados, tais como: limitações do instrumento, condições experimentais, etc.;
- c) O principal método desenvolvido neste caso é **Método dos Mínimos Quadrados**;
- d) No segundo caso, consideramos que não existem erros nos dados e podemos exigir que a curva passe pelos pontos dados. Como veremos, no próximo capítulo, esse problema será resolvido com **interpolação**;
- e) Nesse caso aproximaremos uma função $f(x)$ por uma função polinomial $p(x)$ que passa pelos pontos dados. Assim dado $p(x)$ é possível estimar o valor de $f(\underline{x})$ para um ponto \underline{x} diferente dos pontos dados.


Cálculo Numérico – 2017.2 – Prof. Gustavo Bono




1) Ajuste de Curvas: Introdução



Dados experimentais
(limitações do instrumentos,
condições experimentais, etc.)



Interpolação



Ajuste de curvas
(Método dos Mínimos
Quadrados)

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



1) Ajuste de Curvas: Introdução

O objetivo do presente capítulo consiste em resolver o seguinte problema: aproximar uma função $y = f(x)$ (real e de variável real) por uma função $F(x)$ que seja combinação linear de funções conhecidas, isto é:

$$f(x) \simeq a_0 g_0(x) + a_1 g_1(x) + \dots + a_m g_m(x) = F(x).$$

de tal modo que a distância de $f(x)$ a $F(x)$ seja a menor possível.

A substituição de $f(x)$ por uma função $F(x)$ é indicada quando o uso da função dada oferece alguns inconvenientes, tais como:

- a) $f(x)$ é definida através de processos não-finitos como integrais, soma de séries, etc;
- b) $f(x)$ é conhecida através de pares de pontos, obtidos em experimentos, e desejamos substituí-la por uma função cujo gráfico se ajuste aos pontos observados;

que podem ser afastados através de uma escolha apropriada da função $F(x)$.

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



Método de Mínimos Quadrados



Josef Daniel Huber
1768-1830
(matemático e
astrônomo suíço)



Adrien-Marie Legendre
1752-1833
(matemático francês)



Carl Friedrich Gauss
1777-1855
(matemático alemão)
MMQ (1809)

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



2) Ajuste de Curvas: Método de Mínimos Quadrados

Vamos chamar de $f(x)$ a função que queremos aproximar por uma outra função $g(x)$.

Nem sempre temos uma expressão analítica para $f(x)$.

No **Método dos Mínimos Quadrados (MMQ)** partimos da hipótese de que temos alguma informação sobre a forma de $g(x)$. Poderíamos saber, através da observação dos dados, por exemplo, que $g(x)$ é uma reta,

$$g(x) = c_0 + c_1x$$

ou que é uma parábola,

$$g(x) = c_0 + c_1x + c_2x^2$$

ou que tenha algum outra forma específica.

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



2) Ajuste de Curvas: Método de Mínimos Quadrados

De forma geral, no **caso linear**, vamos considerar que a aproximação será dada por uma função do tipo:

$$g(x) = c_0\phi_0(x) + c_1\phi_1(x) + \dots + c_n\phi_n(x)$$

onde $\phi_0(x), \phi_1(x), \dots, \phi_n(x)$ são **funções pré-estabelecidas** (conhecidas!!).

No **MMQ linear**, a função $g(x)$ que aproxima $f(x)$ é **linear** nos seus parâmetros $c_0, c_1, c_2, \dots, c_n$.

Por exemplo:

$$\phi_0(x) = 1, \quad \phi_1(x) = x, \quad \phi_2(x) = x^2, \quad \dots$$

$$\phi_0(x) = \sin(\pi x), \quad \phi_1(x) = \sin(2\pi x), \quad \dots$$

No caso do **MMQ não linear**, a relação da função $g(x)$ com seus parâmetros $c_0, c_1, c_2, \dots, c_n$, pode ser do tipo, por exemplo:

$$g(x) = c_0 e^{c_1 x}.$$

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



2) Ajuste de Curvas: Método de Mínimos Quadrados

Considerando uma função aproximação do tipo:

$$g(x) = c_0\phi_0(x) + c_1\phi_1(x) + \dots + c_n\phi_n(x)$$

Para cada conjunto de coeficientes $c_i, i = 0, 1, \dots, n$, o **resíduo (desvio) da aproximação** no ponto x_k é dado por:

$$\begin{aligned} r(x_k) &= f(x_k) - g(x_k) \\ &= f(x_k) - [c_0\phi_0(x_k) + c_1\phi_1(x_k) + \dots + c_n\phi_n(x_k)] \\ &= r(x_k; c_0, c_1, \dots, c_n) \end{aligned}$$

Precisamos estabelecer algum critério de aproximação para encaminhar o problema da determinação dos parâmetros $c_0, c_1, c_2, \dots, c_n$ que nos levarão à melhor aproximação.

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



2) Ajuste de Curvas: Método de Mínimos Quadrados

Exemplo 1: Determinar o peso da bike e do ciclista.



$B + C = 67$
 $B = 6$
 $C = 62$

Quanto pesa ciclista + bike ?

Sistema inconsistente !!




2) Ajuste de Curvas: Método de Mínimos Quadrados

Exemplo 1: Determinar o peso da bike e do ciclista.

Precisamos procurar os de B e C que minimizem:


$$P(B,C) = (B + C - 67)^2 + (B - 6)^2 + (C - 62)^2$$

Os valores de P para diferentes valores de B e C ficam:



2) Ajuste de Curvas: Método de Mínimos Quadrados

Exemplo 2: De acordo com a lei de Charles para um gás ideal em um volume constante, existe uma relação linear entre a pressão p e a temperatura T . Obtenha uma aproximação para os seguintes dados experimentais:




Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



2) Ajuste de Curvas: Método de Mínimos Quadrados

Exemplo 2: De acordo com a lei de Charles para um gás ideal em um volume constante, existe uma relação linear entre a pressão p e a temperatura T . Obtenha uma aproximação para os seguintes dados experimentais:

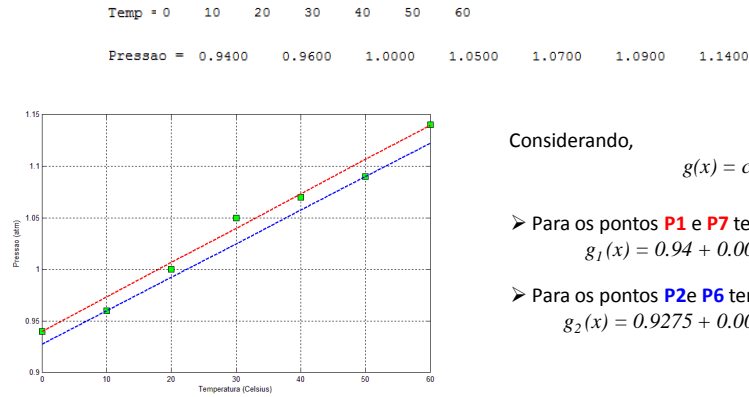


Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



2) Ajuste de Curvas: Método de Mínimos Quadrados

Exemplo 2: De acordo com a lei de Charles para um gás ideal em um volume constante, existe uma relação linear entre a pressão p e a temperatura T . Obtenha uma aproximação para os seguintes dados experimentais:



Considerando,

$$g(x) = c_0 + c_1 x$$

➤ Para os pontos **P1** e **P7** temos:

$$g_1(x) = 0.94 + 0.00333 x$$

➤ Para os pontos **P2** e **P6** temos:


$$g_2(x) = 0.9275 + 0.00325 x$$


2) Ajuste de Curvas: Método de Mínimos Quadrados

Para obter as aproximações g_1 e g_2 desprezamos vários dados da lista para fazer a interpolação !!

Um modo de verificar quão bem a função aproximação é capaz de representar os dados fornecido pode ser obtido com o cálculo do erro total em termos dos resíduos.

Uma definição para o erro global que fornece uma boa medida do erro total e que também pode ser usada para determinar uma única função linear que leve ao melhor ajuste (isto é, ao menor erro total) é obtida fazendo:



2) Ajuste de Curvas: Método de Mínimos Quadrados

Para os pontos **P1 e P7** temos:
 $g_1(x) = 0.94 + 0.00333 x$


x_i	$f(x_i)$	$g(x_i)$	r_i^2
0	0.94	0.94	0
10	0.96	0.97333	0.00017777
20	1	1.0067	4.4436e-005
30	1.05	1.04	0.00010002
40	1.07	1.0733	1.1102e-005
50	1.09	1.1067	0.00027772
60	1.14	1.14	4e-012

$E_1^2 = 0.00061105$

Para os pontos **P2 e P6** temos:
 $g_2(x) = 0.9275 + 0.00325 x$

x_i	$f(x_i)$	$g(x_i)$	r_i^2
0	0.94	0.9275	0.00015625
10	0.96	0.96	0
20	1	0.9925	5.625e-005
30	1.05	1.025	0.000625
40	1.07	1.0575	0.00015625
50	1.09	1.09	0
60	1.14	1.1225	0.00030625

$E_2^2 = 0.0013$



Logo, $g_1(x)$ é mais adequado de acordo com esse critério de erros ao quadrado. Depois de analisar o exemplo, surge a pergunta:

❑ Como escolher c_0 e c_1 de forma que E^2 seja mínimo ?



2) Ajuste de Curvas: Método de Mínimos Quadrados

Até o momento somente falamos em aproximação de dados discretos, isto é, aproximar $f(x)$ sabendo os valores de f em um conjunto de pontos x_i . Também podemos trabalhar com o caso de aproximar $f(x)$, uma função conhecida para todo x , por uma função mais simples como $g(x)$. No **caso contínuo** do método dos mínimos quadrados (MMQ) temos que minimizar:

$$\int_a^b r(x)^2 dx = \int_a^b (f(x) - g(x))^2 dx$$

Para poder medir o resíduo, vamos a introduzir formalmente o conceito de produto escalar entre funções:

$$\langle f, g \rangle = \begin{cases} \sum_{i=1}^m f(x_i)g(x_i), & \text{caso discreto} \\ \int_a^b f(x)g(x) dx, & \text{caso contínuo} \end{cases}$$



2) Ajuste de Curvas: Método de Mínimos Quadrados

O MMQ consiste na procura dos parâmetros (c_0, c_1, \dots, c_n) que minimizem:

- a soma dos quadrados dos resíduos (caso discreto), ou,
- a integral da função resíduo ao quadrado (caso contínuo).

Desta forma, introduzindo a notação do produto escalar obtemos:

$$\langle r, r \rangle = \sum_{i=1}^m [r(x_i)]^2 = \sum_{i=1}^m [f(x_i) - g(x_i)]^2$$

Portanto, $\langle r, r \rangle$ é função dos parâmetros c_0, c_1, \dots, c_n .

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



Método de Mínimos Quadrados
Caso Discreto (Linear)

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



2) Ajuste de Curvas: MMQ – Caso Discreto – Linear

De forma geral, queremos aproximar $f(x)$ por:

$$g(x) = c_0\phi_0(x) + c_1\phi_1(x) + \dots + c_n\phi_n(x)$$

onde $\phi_j(x)$ são funções conhecidas. Assim, para encontrar os parâmetros c_0, c_1, \dots, c_n é preciso minimizar a função:

$$\begin{aligned} \langle r, r \rangle &= \langle f - c_0\phi_0 - \dots - c_n\phi_n, f - c_0\phi_0 - \dots - c_n\phi_n \rangle \\ &= \sum_{i=1}^m \left[f(x_i) - \sum_{j=0}^n c_j\phi_j(x_i) \right]^2 \end{aligned}$$

Observando que $\langle r, r \rangle$ é uma forma quadrática, precisamos derivar com relação a cada um dos parâmetros c_k e igualando a zero temos:

$$\langle r, r \rangle = -2 \sum_{i=1}^m \left[f(x_i) - \sum_{j=0}^n c_j\phi_j(x_i) \right] \phi_k(x_i) = 0$$

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



2) Ajuste de Curvas: MMQ – Caso Discreto – Linear

$$\begin{aligned} & -2 \sum_{i=1}^m \left[f(x_i) - \sum_{j=0}^n c_j\phi_j(x_i) \right] \phi_k(x_i) = 0 \\ \Rightarrow & \sum_{i=1}^m \left\{ \left[f(x_i) - \sum_{j=0}^n c_j\phi_j(x_i) \right] \phi_k(x_i) \right\} = 0 \\ \Rightarrow & \sum_{i=1}^m \left[\sum_{j=0}^n c_j\phi_j(x_i)\phi_k(x_i) \right] = \sum_{i=1}^m f(x_i)\phi_k(x_i) \\ \Rightarrow & \sum_{j=0}^n c_j \left(\sum_{i=1}^m \phi_j(x_i)\phi_k(x_i) \right) = \sum_{i=1}^m f(x_i)\phi_k(x_i) \end{aligned}$$

Lembrando que:

$$\langle f, g \rangle = \sum_{i=1}^m f(x_i)g(x_i)$$

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



2) Ajuste de Curvas: MMQ – Caso Discreto – Linear

Empregando a notação de produto escalar, podemos escrever:

$$\Rightarrow \sum_{j=0}^n c_j \underbrace{\left(\sum_{i=1}^m \phi_j(x_i) \phi_k(x_i) \right)}_{\langle \phi_j, \phi_k \rangle = \langle \phi_k, \phi_j \rangle} = \underbrace{\sum_{i=1}^m f(x_i) \phi_k(x_i)}_{\langle f, \phi_k \rangle = \langle \phi_k, f \rangle}$$

$$\Rightarrow \sum_{j=0}^n c_j \langle \phi_k, \phi_j \rangle = \langle f, \phi_k \rangle \quad \text{para } k = 0, 1, \dots, n$$

que representa um sistema de equações lineares $(n+1, n+1)$.

Por exemplo para $n=2$:

$$\begin{aligned} \langle \phi_0, \phi_0 \rangle c_0 + \langle \phi_0, \phi_1 \rangle c_1 + \langle \phi_0, \phi_2 \rangle c_2 &= \langle \phi_0, f \rangle \\ \langle \phi_1, \phi_0 \rangle c_0 + \langle \phi_1, \phi_1 \rangle c_1 + \langle \phi_1, \phi_2 \rangle c_2 &= \langle \phi_1, f \rangle \\ \langle \phi_2, \phi_0 \rangle c_0 + \langle \phi_2, \phi_1 \rangle c_1 + \langle \phi_2, \phi_2 \rangle c_2 &= \langle \phi_2, f \rangle \end{aligned}$$

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



2) Ajuste de Curvas: MMQ – Caso Discreto – Linear

Escrevendo de forma matricial:

$$\begin{bmatrix} \langle \phi_0, \phi_0 \rangle & \langle \phi_0, \phi_1 \rangle & \langle \phi_0, \phi_2 \rangle \\ \langle \phi_1, \phi_0 \rangle & \langle \phi_1, \phi_1 \rangle & \langle \phi_1, \phi_2 \rangle \\ \langle \phi_2, \phi_0 \rangle & \langle \phi_2, \phi_1 \rangle & \langle \phi_2, \phi_2 \rangle \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} \langle \phi_0, f \rangle \\ \langle \phi_1, f \rangle \\ \langle \phi_2, f \rangle \end{bmatrix}$$

De forma geral, o sistema pode ser representado por:

$$\begin{bmatrix} \langle \phi_0, \phi_0 \rangle & \langle \phi_0, \phi_1 \rangle & \dots & \langle \phi_0, \phi_n \rangle \\ \langle \phi_1, \phi_0 \rangle & \langle \phi_1, \phi_1 \rangle & \dots & \langle \phi_1, \phi_n \rangle \\ \vdots & \vdots & \ddots & \vdots \\ \langle \phi_n, \phi_0 \rangle & \langle \phi_n, \phi_1 \rangle & \dots & \langle \phi_n, \phi_n \rangle \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ \vdots \\ c_n \end{bmatrix} = \begin{bmatrix} \langle \phi_0, f \rangle \\ \langle \phi_1, f \rangle \\ \vdots \\ \langle \phi_n, f \rangle \end{bmatrix}$$

o qual é chamado de **sistema normal** ou **equações normais**.

IMPORTANTE: pelo fato de $\langle f, g \rangle = \langle g, f \rangle$ a matriz é **simetria**.

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



2) Ajuste de Curvas: MMQ – Caso Discreto – Linear

Exemplo 3: Aplique o MMQ para a tabela de dados:

$x_i =$	0	0.25	0.5	0.75	1
$f(x_i) =$	1	1.284	1.6487	2.117	2.7183

Aproximar a função por um polinômio linear.


$$g(x) = c_0 \phi_0(x) + c_1 \phi_1(x),$$

$$g(x) = c_0 + c_1 x$$

$$\phi_0(x) = 1, \quad \phi_1(x) = x.$$

O sistema que precisamos resolver é dado por:

$$\begin{bmatrix} \langle \phi_0, \phi_0 \rangle & \langle \phi_0, \phi_1 \rangle \\ \langle \phi_1, \phi_0 \rangle & \langle \phi_1, \phi_1 \rangle \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \end{bmatrix} = \begin{bmatrix} \langle \phi_0, f \rangle \\ \langle \phi_1, f \rangle \end{bmatrix}$$



Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



2) Ajuste de Curvas: MMQ – Caso Discreto – Linear

Exemplo 3: Aplique o MMQ para a tabela de dados:

$x_i =$	0	0.25	0.5	0.75	1
$f(x_i) =$	1	1.284	1.6487	2.117	2.7183


Aproximar a função por um polinômio linear.

$$\phi_0(x) = 1, \quad \phi_1(x) = x,$$

$$\phi_0 = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}, \quad \phi_1 = \begin{bmatrix} 0 \\ 0,25 \\ 0,5 \\ 0,75 \\ 1 \end{bmatrix}$$

Calculando os produtos escalares, obtemos:

$$\begin{aligned} \langle \phi_0, \phi_0 \rangle &= 5 & \langle f, \phi_0 \rangle &= 8,768 \\ \langle \phi_0, \phi_1 \rangle &= 2,5 & \langle f, \phi_1 \rangle &= 5,4514 \\ \langle \phi_1, \phi_1 \rangle &= 1,875 \end{aligned}$$



Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



2) Ajuste de Curvas: MMQ – Caso Discreto – Linear


Exemplo 3: Aplique o MMQ para a tabela de dados:

$x_i =$	0	0.25	0.5	0.75	1
$f(x_i) =$	1	1.284	1.6487	2.117	2.7183

Aproximar a função por um polinômio linear.

$$\begin{aligned} 5c_0 + 2.5c_1 &= 8.768 \\ 2.5c_0 + 1.875c_1 &= 5.4514 \end{aligned}$$

$$\begin{aligned} c_0 &= 0.89968 \\ c_1 &= 1.70784 \Rightarrow g(x) = 0.89968 + 1.70784x \end{aligned}$$




2) Ajuste de Curvas: MMQ – Caso Discreto – Linear

Exemplo 4: Aplique o MMQ para a tabela de dados:

$x_i =$	0	0.25	0.5	0.75	1
$f(x_i) =$	-153	64	242	284	175

Aproximar a função por um polinômio de grau 2.



2) Ajuste de Curvas: MMQ – Caso Discreto – Linear

Exemplo 4: Aplique o MMQ para a tabela de dados:


$x_i =$	0	0.25	0.5	0.75	1
$f(x_i) =$	-153	64	242	284	175

Aproximar a função por um polinômio de grau 2.

$g(x) = c_0\phi_0(x) + c_1\phi_1(x) + c_2\phi_2(x),$

$g(x) = c_0 + c_1x + c_2x^2$

$\phi_0(x) = 1, \quad \phi_1(x) = x, \quad \phi_2(x) = x^2$



$g(x) = -165.3714 + 1250.9714x - 900.5714x^2$

$$\begin{bmatrix} \langle \phi_0, \phi_0 \rangle & \langle \phi_0, \phi_1 \rangle & \langle \phi_0, \phi_2 \rangle \\ \langle \phi_1, \phi_0 \rangle & \langle \phi_1, \phi_1 \rangle & \langle \phi_1, \phi_2 \rangle \\ \langle \phi_2, \phi_0 \rangle & \langle \phi_2, \phi_1 \rangle & \langle \phi_2, \phi_2 \rangle \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} \langle \phi_0, f \rangle \\ \langle \phi_1, f \rangle \\ \langle \phi_2, f \rangle \end{bmatrix}$$



Método de Mínimos Quadrados
Caso Discreto (Não Linear)



3) Ajuste de Curvas: MMQ – Caso Discreto – Não Linear

Em muitos casos, precisamos ajustar uma curva $g(x)$ que é uma função não linear dos parâmetros. Por exemplo:

$$\begin{aligned} g(x) &= c_0 e^{c_1 x} \\ g(x) &= c_0 x^{c_1} \\ g(x) &= \frac{1}{c_0 + c_1 x} \\ g(x) &= c_0 c_1^x \end{aligned}$$

Uma forma de tratar esse problema é através da **transformação** do modelo não linear em um modelo linear (**linearização** ou **mudança de variável**). Para entender o procedimento vamos a considerar o seguinte exemplo.




3) Ajuste de Curvas: MMQ – Caso Discreto – Não Linear

Exemplo 5: Considerando a seguinte tabela de dados, ajuste os mesmos com a função exponencial $f(x) = \beta_1 e^{\beta_2 x}$.

$$\begin{aligned} x_i &= (-1, -0.7, -0.4, -0.1, 0.2, 0.5, 0.8, 1)^T \\ f(x_i) &= (36.54, 17.26, 8.15, 3.85, 1.82, 0.86, 0.4, 0.24)^T \end{aligned}$$

$$\begin{bmatrix} \langle \phi_0, \phi_0 \rangle & \langle \phi_0, \phi_1 \rangle \\ \langle \phi_1, \phi_0 \rangle & \langle \phi_1, \phi_1 \rangle \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \end{bmatrix} = \begin{bmatrix} \langle \phi_0, F \rangle \\ \langle \phi_1, F \rangle \end{bmatrix}$$




3) Ajuste de Curvas: MMQ – Caso Discreto – Não Linear

Exemplo 5: Considerando a seguinte tabela de dados, ajuste os mesmos com a função exponencial $f(x) = \beta_1 e^{\beta_2 x}$.

$$x_i = (-1, -0.7, -0.4, -0.1, 0.2, 0.5, 0.8, 1)^T$$
$$f(x_i) = (36.54, 17.26, 8.15, 3.85, 1.82, 0.86, 0.4, 0.24)^T$$

$$\begin{bmatrix} 8.0 & 0.30 \\ 0.30 & 3.59 \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \end{Bmatrix} = \begin{Bmatrix} 8.0 \\ -8.68 \end{Bmatrix}$$



Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



3) Ajuste de Curvas: MMQ – Caso Discreto – Não Linear

NOTA: os coeficientes obtidos a partir da linearização são aproximados, ou seja, são diferentes daqueles obtidos quando aplicamos mínimos quadrados não linear. Observe que estamos minimizando $\sum_i [\ln y_i - \ln(f(x_i))]^2$ em vez de $\sum_i [y_i - f(x_i)]^2$.

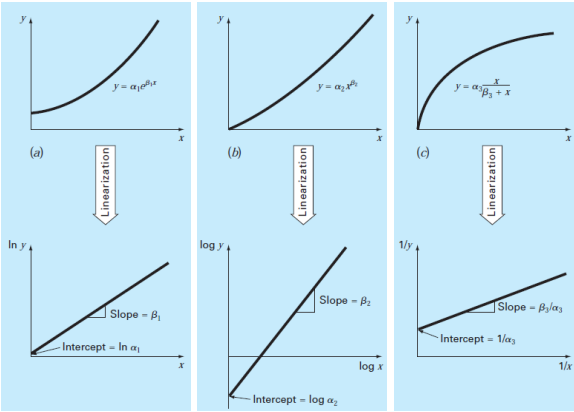
Na próxima tabela mostram-se algumas curvas e transformações que linearizam o problema de ajuste.

Curva	Transformação	Problema Linearizado
$y = ae^{bx}$	$\tilde{y} = \ln y$	$\tilde{y} = \ln a + bx$
$y = ax^b$	$\tilde{y} = \ln y$	$\tilde{y} = \ln a + b \ln x$
$y = ax^b e^{cx}$	$\tilde{y} = \ln y$	$\tilde{y} = \ln a + b \ln x + cx$
$y = ae^{(b+cx)^2}$	$\tilde{y} = \ln y$	$\tilde{y} = \ln a + b^2 + bcx + c^2 x^2$
$y = \frac{a}{b+x}$	$\tilde{y} = \frac{1}{y}$	$\tilde{y} = \frac{b}{a} + \frac{1}{a}x$
$y = A \cos(\omega x + \phi)$ ω conhecido	—	$y = a \cos(\omega x) - b \sin(\omega x)$ $a = A \cos(\phi), b = A \sin(\phi)$

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



3) Ajuste de Curvas: MMQ – Caso Discreto – Não Linear



Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



Método de Mínimos Quadrados
Caso Contínuo

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



3) Ajuste de Curvas: MMQ – Caso Contínuo

Até o momento foi apresentado como aproximar uma função $f(x)$ por uma função $g(x)$ em um conjunto de pontos x_i onde conhecemos o valor de $f(x_i)$. → **CASO DISCRETO**

Agora vamos a considerar o **CASO CONTÍNUO**, onde queremos aproximar $f(x)$ que é uma função conhecida para todo x em um intervalo $[a, b]$, por uma função $g(x)$ definida na forma:

$$g(x) = c_0\phi_0(x) + c_1\phi_1(x) + \dots + c_n\phi_n(x)$$

onde $\phi_0(x), \dots, \phi_n(x)$ são funções contínuas e conhecidas.

➤ Inicialmente, para apresentar o método vamos a considerar o seguinte caso:

$$g(x) = c_0\phi_0(x) + c_1\phi_1(x)$$

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



3) Ajuste de Curvas: MMQ – Caso Contínuo

Lembrando, ver *slide 12*, que o produto escalar entre duas funções contínuas no intervalo $[a, b]$ é definido por:

$$\langle f, g \rangle = \int_a^b f(x)g(x) dx$$

Podemos então medir a distância entre as funções $f(x)$ e $g(x)$ fazendo:

$$\langle f - g, f - g \rangle = \int_a^b [f(x) - g(x)]^2 dx$$

NOTA: no caso discreto empregamos

$$\langle f - g, f - g \rangle = \sum_{i=1}^m [f(x_i) - g(x_i)]^2$$

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



3) Ajuste de Curvas: MMQ – Caso Contínuo

Considerando o resíduo, $r = f - g$, temos:

$$\begin{aligned} \langle r, r \rangle &= \int_a^b [f(x) - g(x)]^2 dx = \int_a^b [f - c_0\phi_0 - c_1\phi_1]^2 dx \\ &= \int_a^b [f^2 - 2c_0f\phi_0 - 2c_1f\phi_1 + c_0^2\phi_0^2 + 2c_0c_1\phi_0\phi_1 + c_1^2\phi_1^2] dx \\ &= \int_a^b f^2 dx - 2c_0 \int_a^b f\phi_0 dx - 2c_1 \int_a^b f\phi_1 dx \\ &\quad + c_0^2 \int_a^b \phi_0^2 dx + 2c_0c_1 \int_a^b \phi_0\phi_1 dx + c_1^2 \int_a^b \phi_1^2 dx \end{aligned}$$

No método dos mínimos quadrados (MMQ) procuramos o ponto de mínimo da função dada por

$$\langle r, r \rangle = \langle r, r \rangle (c_0, c_1).$$

Portanto, precisamos calcular as derivadas parciais de $\langle r, r \rangle$ com relação a c_0 e c_1 .

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



3) Ajuste de Curvas: MMQ – Caso Contínuo

Calculando as derivadas parciais e igualando a zero, podemos escrever:

$$\begin{aligned} \frac{\partial \langle r, r \rangle}{\partial c_0} &= -2 \int_a^b f\phi_0 dx + 2c_0 \int_a^b \phi_0\phi_0 dx + 2c_1 \int_a^b \phi_0\phi_1 dx = 0 \\ \frac{\partial \langle r, r \rangle}{\partial c_1} &= -2 \int_a^b f\phi_1 dx + 2c_1 \int_a^b \phi_1\phi_1 dx + 2c_0 \int_a^b \phi_0\phi_1 dx = 0 \end{aligned}$$

organizando os termos, temos o seguinte sistema:

$$\begin{aligned} c_0 \int_a^b \phi_0\phi_0 dx + c_1 \int_a^b \phi_0\phi_1 dx &= \int_a^b f\phi_0 dx \\ c_1 \int_a^b \phi_1\phi_1 dx + c_0 \int_a^b \phi_0\phi_1 dx &= \int_a^b f\phi_1 dx \end{aligned}$$

usando a definição de produto escalar, o sistema em forma compacto fica:

$$\langle \phi_i, \phi_j \rangle = \int_a^b \phi_i(x)\phi_j(x) dx$$

$$c_0 \langle \phi_0, \phi_0 \rangle + c_1 \langle \phi_0, \phi_1 \rangle = \langle f, \phi_0 \rangle$$

$$c_0 \langle \phi_1, \phi_0 \rangle + c_1 \langle \phi_1, \phi_1 \rangle = \langle f, \phi_1 \rangle$$

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



3) Ajuste de Curvas: MMQ – Caso Contínuo

O sistema de equações lineares (**equações normais**), pode ser escrito de forma matricial como:

$$\begin{bmatrix} \langle \phi_0, \phi_0 \rangle & \langle \phi_0, \phi_1 \rangle \\ \langle \phi_1, \phi_0 \rangle & \langle \phi_1, \phi_1 \rangle \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \end{bmatrix} = \begin{bmatrix} \langle f, \phi_0 \rangle \\ \langle f, \phi_1 \rangle \end{bmatrix}$$

NOTA: o procedimento de cálculo é similar ao caso discreto, a diferença é na forma de calcular os produtos escalares, pois no caso contínuo temos que calcular as integrais definidas por:

$$\langle \phi_i(x), \phi_j(x) \rangle = \int_a^b \phi_i(x) \phi_j(x) dx$$

$$\langle f(x), \phi_i(x) \rangle = \int_a^b f(x) \phi_i(x) dx$$

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono




3) Ajuste de Curvas: MMQ – Caso Contínuo

Exemplo 6: Encontre a reta que melhor aproxima $f(x) = 4x^3$ em $[0, 1]$ usando o Método dos Mínimos Quadrados.

$$\begin{bmatrix} \langle \phi_0, \phi_0 \rangle & \langle \phi_0, \phi_1 \rangle \\ \langle \phi_1, \phi_0 \rangle & \langle \phi_1, \phi_1 \rangle \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \end{bmatrix} = \begin{bmatrix} \langle f, \phi_0 \rangle \\ \langle f, \phi_1 \rangle \end{bmatrix}$$

$$\begin{bmatrix} \langle 1, 1 \rangle & \langle 1, x \rangle \\ \langle x, 1 \rangle & \langle x, x \rangle \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \end{bmatrix} = \begin{bmatrix} \langle f, 1 \rangle \\ \langle f, x \rangle \end{bmatrix}$$



Cálculo Numérico – 2017.2 – Prof. Gustavo Bono




3) Ajuste de Curvas: MMQ – Caso Contínuo

Exemplo 6: Encontre a reta que melhor aproxima $f(x) = 4x^3$ em $[0, 1]$ usando o Método dos Mínimos Quadrados.

$$\begin{bmatrix} \langle \phi_0, \phi_0 \rangle & \langle \phi_0, \phi_1 \rangle \\ \langle \phi_1, \phi_0 \rangle & \langle \phi_1, \phi_1 \rangle \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \end{bmatrix} = \begin{bmatrix} \langle f, \phi_0 \rangle \\ \langle f, \phi_1 \rangle \end{bmatrix}$$

$$\begin{bmatrix} \langle 1, 1 \rangle & \langle 1, x \rangle \\ \langle x, 1 \rangle & \langle x, x \rangle \end{bmatrix} \begin{Bmatrix} c_0 \\ c_1 \end{Bmatrix} = \begin{Bmatrix} \langle f, 1 \rangle \\ \langle f, x \rangle \end{Bmatrix}$$



$$g(x) = -\frac{4}{5} + \frac{18}{5}x$$

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono



3) Ajuste de Curvas: MMQ – Caso Contínuo

Exemplo 7: Encontre o polinômio de segundo grau que melhor aproxima $f(x) = x^4 - 5x$ em $[-1, 1]$ usando o Método dos Mínimos Quadrados.

$$\begin{bmatrix} \langle 1, 1 \rangle & \langle 1, x \rangle & \langle 1, x^2 \rangle \\ \langle x, 1 \rangle & \langle x, x \rangle & \langle x, x^2 \rangle \\ \langle x^2, 1 \rangle & \langle x^2, x \rangle & \langle x^2, x^2 \rangle \end{bmatrix} \begin{Bmatrix} c_0 \\ c_1 \\ c_2 \end{Bmatrix} = \begin{Bmatrix} \langle f, 1 \rangle \\ \langle f, x \rangle \\ \langle f, x^2 \rangle \end{Bmatrix}$$

$$g(x) = -\frac{3}{35} - 5x + \frac{6}{7}x^2$$

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono





Dúvidas ??

Obrigado

*Críticas e sugestões serão bem-vindas, pois assim poderão ser melhoradas as aulas/slides.
bonogustavo@gmail.com*

Cálculo Numérico – 2017.2 – Prof. Gustavo Bono

